Capítulo 8. Conclusiones y Trabajos Futuros

8.1. Conclusiones

A lo largo de este proyecto de tesis, se trabajó para lograr determinar si el uso de técnicas de PLN basadas en aprendizaje profundo era eficaz para generar contenido útil en la lengua Iskonawa. Es decir, que se logre producir contenido que pueda ser utilizado en la creación de futuros corpus para promover la investigación en esta lengua de bajos recursos.

En primer lugar, se diseñó y desarrolló un corpus monolingüe del idioma Iskonawa en base a los datos de una investigación previa para cumplir con el primer objetivo específico (O1). Este corpus fue estructurado para reunir todo el conocimiento lingüístico presente en los datos (esto incluye segmentaciones morfológicas, glosas, etiquetado de partes del habla y traducciones libres) y ser computacionalmente fácil de usar. (R1.1). Posteriormente, se completó el desarrollo del corpus, el cual se compartió públicamente en un formato JSON en un repositorio para su uso en futuras investigaciones (R1.2). La cantidad de registros final en el corpus fue de 3942.

El siguiente paso consistió en aplicar técnicas de preprocesamiento, aumentación y vectorización de datos del corpus (O2). Dentro de la etapa de preprocesamiento, se consideró una limpieza de caracteres especiales y espacios en blanco, así como una tokenización en subpalabras mediante el algoritmo Byte-pair encoding, En la aumentación se incluyeron inserciones de ruido aleatorias y cambios aleatorios en determinados morfemas. Finalmente, se probaron 3 técnicas de vectorización distintas. Este pipeline fue validado por un experto en procesamiento de lenguaje natural (R2.1) y, luego de su desarrollo, fue probado en una tarea de clusterización. En esta tarea se tomaron en cuenta las métricas de Silhouette Score, Índice de Davies-Bouldin y el Índice de Calinski-Harabasz (R2.2). Los resultados obtenidos indicaron que se logró un agrupamiento más adecuado con la técnica de vectorización de Embeddings anclados. Además, luego de someter al conjunto de datos inicial al pipeline, se contó un corpus aumentado de 7720 registros.

Seguidamente, se eligieron y entrenaron modelos de generación automática de texto basados en aprendizaje profundo para alcanzar el tercer objetivo (O3). En la primera etapa de este objetivo, se consultó la literatura encontrada durante la revisión sistemática para elegir las técnicas y arquitecturas a utilizar. Se eligieron finalmente 3 referencias a probar: ZmBART,

MetaXNLG y XNLG. En adición a estas tres técnicas, se decidió entrenar desde cero a un modelo LSTM y un modelo T5 con el fin de servir como línea base. Esta definición fue validada por un experto y se continuó con el entrenamiento (R3.1). Las técnicas y modelos fueron replicadas y adaptadas para trabajar con los recursos que se contaba. Luego de terminar su entrenamiento, se generó contenido y se ejecutaron 3 métricas automáticas (perplejidad, N-Score y MAUVE) (R3.2). Ninguno de los modelos tuvo un desempeño destacable en ninguna de las métricas, lo cual llevó a considerar que no estaban produciendo contenido útil. Sin embargo, esto se comprobó en el siguiente objetivo.

El último objetivo específico consistió en desarrollar un prototipo de aplicación para validar el contenido de los modelos generativos con expertos en la lengua. La arquitectura del prototipo fue diseñada para asegurar que pueda ser usada en otras lenguas, con otros modelos, con otro contenido a validar y con otras métricas de las usadas en este proyecto. (R4.1). Además, se estableció un protocolo para la revisión manual de la calidad del contenido generado que se seguiría en esta aplicación. Específicamente, se consideró en las validaciones a realizar las métricas de Pertinencia, Correctitud y Fluidez (R4.2). El flujo de uso del prototipo fue validado con 5 usuarios para identificar ambigüedades e inconsistencia en su usabilidad. Una vez estas fueron corregidas, el prototipo fue desplegado exitosamente, se cargaron los datos a validar y se compartió el enlace con el experto para validar el contenido generado durante el proyecto (R4.3). Una vez el experto terminó de validar el contenido, se identificó que ninguno de los modelos superaba al mismo tiempo el 70% en las métricas de fluidez, correctitud y pertinencia. Por otro lado, los ejemplos producidos por la aumentación puntuaron un 85% del máximo en fluidez y correctitud y todos fueron catalogados como aparentemente Iskonawa.

En conclusión, este trabajo permitió identificar que, con el volumen limitado de datos disponibles en la lengua Iskonawa, los métodos de aprendizaje profundo de PLN probados, incluso siendo estos pensados específicamente para lenguas de bajos recursos, no logran generar contenido útil. De acuerdo a las evaluaciones del experto, no cumplen los requisitos de fluidez ni correctitud, lo cual los convierte en no aptos para formar parte de un nuevo corpus. Sin embargo, los ejemplos obtenidos de la aumentación obtuvieron puntajes similares a los ejemplos reales, lo que sugiere que en trabajos futuros debería explotarse más este enfoque.

8.2. Trabajos Futuros

A lo largo del desarrollo de esta tesis, se identificaron 3 oportunidades claras para continuar con el trabajo en lenguas de bajos recursos:

- **Profundización en métodos basados en reglas para la aumentación.** Se puede continuar con las técnicas de aumentación descritas en el Capítulo 5 e incorporar otras más que se enfoquen en utilizar anotaciones lingüísticas para incrementar el número de datos. Se podrían generalizar más los métodos al usar estándares como UniMorph o Universal Dependencies y ejecutar técnicas que no pudieron usarse en este proyecto como la rotación de árboles de dependencia. Esta solución podría desarrollarse con la característica de ser configurable y empaquetarse en un paquete de Python para su distribución. El valor de esta iniciativa estaría en aprovechar el máximo el conocimiento lingüístico en corpus anotados.
- **Reforzar la aplicación de validación para pruebas con nativos.** Durante el desarrollo de la aplicación de validación, tanto las personas que ejecutaron las pruebas como el experto que usó la aplicación fueron personas, en mayor o menor grado, familiares con la tecnología. Sin embargo, una de las categorías de evaluadores eran personas hablantes nativas. Estas personas no necesariamente han tenido o tienen contacto constante con tecnología. En ese sentido, un futuro proyecto podría enfocarse en hacer mucho más accesible el protocolo de validación y las interfaces de la aplicación. De esta forma, su uso podría brindar valor en validaciones con hablantes nativos no necesariamente familiares con la tecnología.
- **Explorar técnicas de aprendizaje profundo desde otro enfoque.** En este proyecto, se intentó entrenar modelos de aprendizaje profundo para generar texto en Iskonawa. Sin embargo, tomar otro enfoque para el uso de estas técnicas podría dar mejores resultados. Por ejemplo, se identificó un estudio (Yong et al., 2024) en donde se presenta un método que busca generar contenido en lenguas de bajos recursos mediante una traducción palabra por palabra de oraciones generadas en alguna otra lengua (español o inglés). Sin embargo, la generación de estas oraciones se limita de acuerdo a un diccionario bilingüe para solo obtener oraciones con palabras que puedan traducirse con dicho lexicón. Es decir, se pueden explorar otras técnicas donde se combinen los pocos recursos en Iskonawa que se tienen con grandes modelos de lenguaje sin necesariamente entrenar esos modelos directamente en Iskonawa.