Capítulo 1. Generalidades

1.1. Problemática

En esta sección se detalla la problemática que la presente tesis abordará. Se empieza diagramando la relación entre la dificultad para crear nuevos corpus con sus causas y consecuencias mediante la técnica del árbol de problemas. Luego, se entra en detalle a una contextualización que permite entender por qué es importante aliviar este problema y facilitar la creación de nuevos corpus. En dicha sección se explicitará el problema seleccionado y se justificará por qué es importante solucionarlo.

1.1.1. Árbol de problemas.

La esquematización del problema central con sus problemas causa y problemas efecto se realiza a través de la técnica del árbol de problemas (Sánchez, 2007). Este diagrama resume la situación del problema analizado en la siguiente sección con el fin de facilitar el entendimiento de las causas y efectos de la dificultad para crear nuevos corpus en Iskonawa. Dicho esquema se muestra en la Figura 1.

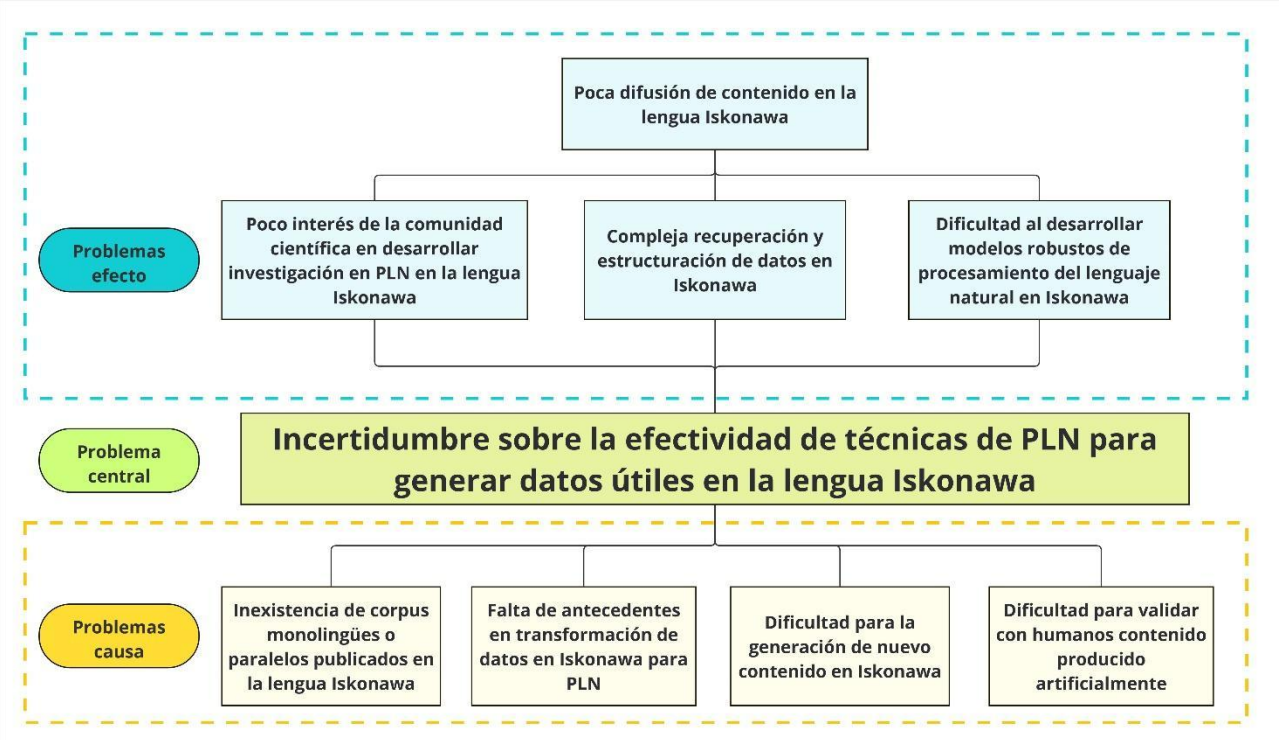

Figura 1. Árbol de problemas planteado.

1.1.2. Descripción.

El 42% de las lenguas del mundo se encuentra en una situación de peligro (Ethnologue, 2021). La desaparición de estas lenguas conlleva a distintos efectos negativos. Por ejemplo, atenta directamente contra la diversidad cultural, pues las lenguas son consideradas un vector crítico en el mantenimiento de esta diversidad (Romaine, 2015). Además, su extinción conlleva una pérdida de conocimiento. Ya sea en la forma de legado cultural a través de canciones, poemas y cuentos (Harrison, 2007) o quizá en áreas más específicas como el conocimiento médico a través de plantas medicinales (Cámara-Leret y Bascompte, 2021).

Aterrizando en la realidad nacional, en el Perú existen 48 lenguas oficialmente reconocidas por el Estado. Cuatro de estas se hablan en los Andes, mientras que las 44 restantes pertenecen a diversas comunidades de la Amazonía (Ministerio de Cultura, 2021). Además, 21 de estas lenguas están consideradas en situación de peligro por el Decreto Supremo[1]. Mediante las categorías de "en peligro", "seriamente en peligro" o "situación crítica", el Ministerio de Cultura del Perú reconoce la condición de vulnerabilidad de estas lenguas (2021).

El Iskonawa, de la familia lingüística Pano, es una de esas lenguas. De acuerdo a la Base de Datos de Pueblos Indígenas u Originarios del Ministerio de Cultura, solo 22 personas reportaron haber aprendido el Iskonawa como lengua materna en su niñez (Ministerio de Cultura, s. f.). Además, el portal Ethnologue la clasifica en un nivel EGIDS 8b (casi extinta) (Eberhard et al., 2024). No solo esta lengua está en peligro, si no que existen escasos estudios centrados en su documentación y recolección de conocimiento (Mazzoti et al., 2018).

Así, la historia de esta lengua es una en la que su pueblo paulatinamente se fue integrando a uno más grande y vio desaparecer su cultura y su lengua (Zariquiey, 2015). Ante ello, Zariquiey (2015) realizó un bosquejo de la gramática del Iskonawa con la esperanza de ayudar a diseñar estrategias para la revitalización. Este proceso fue complicado, dada la poca cantidad de hablantes y la naturaleza no estructurada de los datos (audios, videos). Frente a ello, la informática puede resultar una importante fuente de ayuda, como, por ejemplo, mediante el software ELAN (Zariquiey, 2015). Esta es una herramienta que se enfoca en complementar el proceso de anotado de audios y videos (*ELAN*, 2023) y que fue usada en dicha investigación para transcribir y traducir los datos.

Así como esta, existen otras formas en las que la informática puede apoyar en proyectos de investigación relacionados al estudio del lenguaje. Por ejemplo, desde el procesamiento del lenguaje natural (PLN), se desarrollan aplicaciones que buscan analizar y representar el

[1] Decreto Supremo N° 009-2021-MC

lenguaje humano automáticamente (Cambria y White, 2014). Sin embargo, volviendo al Iskonawa, aún no se cuenta con proyectos de este tipo para esta lengua y lo más cercano son investigaciones en el Shipibo-Konibo, otra lengua de la familia Pano (Oncevay et al., 2022; Vasquez et al., 2018).

Precisamente, este es uno de los principales retos en el PLN: la gran mayoría de investigaciones en esta área se centran en solo 20 de las lenguas del mundo (Magueresse et al., 2020). En el resto de lenguas, usualmente conocidas como lenguas de bajos recursos (Hämäläinen, 2021), la falta de grandes corpus de datos monolingües o paralelos hace más complicado conseguir resultados satisfactorios (Kaddari et al., 2021). Si bien investigaciones recientes (Chi et al., 2019; Maurya et al., 2021; Maurya y Desarkar, 2022) han intentado lidiar con la poca cantidad de datos mediante el uso de técnicas como la transferencia de aprendizaje y modelos pre-entrenados (ver Marco Referencial), estas no han sido probadas en Iskonawa ni lenguas cercanas.

La carencia del desarrollo de estas tecnologías o proyectos exacerba la marginalización lingüística que los hablantes de estas lenguas sufren (S. Zhang et al., 2022). Esto impacta la cantidad de personas que adquieren estas lenguas, lo que a su vez, lleva de nuevo a dificultar el desarrollo de aplicaciones de PLN (S. Zhang et al., 2022).

Además, muchos de los datos en estas lenguas, si es que existen, están guardados en archivos lingüísticos no muy conocidos por la comunidad de PLN o bloqueados tras barreras que impiden el acceso público (Zariquiey et al., 2022). Mucha de esta data se encuentra en formatos poco estructurados, como archivos PDF de material educativo (Bustamante et al., 2020). Es decir, resulta complicado acceder a datos necesarios para empezar a desarrollar aplicaciones de PLN.

Pero, ¿por qué preocuparse en desarrollar proyectos de PLN en estas lenguas? En adición a las posibles mejoras en técnicas de PLN que traería el estudio de una mayor diversidad de lenguas (Bender, 2011), estas aplicaciones pueden ser utilizadas con el fin de preservación lingüística. Por ejemplo, se han reportado plataformas con contenido generado y evaluado automáticamente para el aprendizaje de idiomas (S. Zhang et al., 2022), traductores automáticos (S. Zhang et al., 2020) o herramientas de ayuda en el proceso de documentación lingüística (Zariquiey et al., 2022). Es decir, se aprecia cómo aplicaciones de PLN han demostrado ayudar con el proceso de revitalización (Flavelle y Lachler, 2023). Adicionalmente, las comunidades poseedoras de estas lenguas han recibido de buena manera esta digitalización al tomarla como una estrategia de reivindicar el valor de sus idiomas (Zariquiey et al., 2022).

Por una parte, se mencionó que la pérdida de lenguas conlleva a efectos negativos para la sociedad. Por otra, se mostró que los proyectos de procesamiento del lenguaje natural pueden ayudar a revitalizar a las lenguas en peligro, como el Iskonawa. Además, los datos necesarios para desarrollar estas aplicaciones son inexistentes, escasos, difíciles de crear o conseguir y complicados de usar. Es decir, los problemas descritos obstaculizan la creación de corpus en esta lengua, los cuales son de vital importancia para el desarrollo de proyectos de PLN. Si bien ha habido esfuerzos en la literatura para trabajar con lenguas de pocos recursos, estas técnicas aún no han sido probadas en el contexto de una lengua con tan pocos recursos como el Iskonawa. Entonces surge la pregunta, **¿permiten estas técnicas aún no exploradas generar contenido útil en Iskonawa que conlleve a construir nuevos corpus de datos?**

La presente tesis se centrará en darle solución a esta interrogante mediante la adaptación de una serie de técnicas para la generación de lenguaje natural en lenguas de bajos. Se realizará una comparación y se evaluará con ayuda de un experto humano la utilidad del contenido generado. En base a una revisión del estado del arte descrita en una posterior sección, se planea utilizar técnicas de aprendizaje profundo para elaborar estos modelos generativos. Esto se realizará en base a modelos pre-entrenados basados en Transformers y se esperan utilizar técnicas de transferencia de aprendizaje. Asimismo, se planea utilizar métodos de preprocesamiento de datos ligadas a las mejores formas de representar vectorialmente el texto y a las técnicas utilizadas para aumentar la cantidad de datos con los que se dispone.

1.1.3. Problema seleccionado.

En base a la problemática anteriormente descrita, el problema central que este trabajo busca tratar es la *Incertidumbre sobre la efectividad de técnicas de PLN para generar datos útiles en la lengua Iskonawa* y espera ayudar a solucionarla mediante el uso de una serie de estas técnicas y la validación del contenido generado para llenar esa laguna de conocimiento actual respecto al mejor camino a tomar para generar nuevos datos en una lengua con tan pocos recursos.

1.2. Objetivos

En esta sección se detalla el objetivo general de este proyecto de tesis, así como los objetivos específicos que desglosan y explican cómo se conseguirá cumplir el objetivo general.

1.2.1. Objetivo general.

Adaptar y desarrollar modelos de generación de texto en Iskonawa mediante métodos del procesamiento de lenguaje natural para evaluar su efectividad en el incremento de la cantidad de datos en esta lengua y contribuir al desarrollo de futuros corpus.

1.2.2. Objetivos específicos.

O1. Diseñar y desarrollar un corpus monolingüe de la lengua Iskonawa.

O2. Aplicar técnicas de preprocesamiento, aumentación y vectorización al conjunto de datos en Iskonawa para definir una estructura de trabajo replicable para futuros proyectos.

O3. Diseñar modelos de generación automática de texto para la lengua Iskonawa basados en aprendizaje profundo.

O4. Elaborar un prototipo de aplicación que use el contenido de los modelos generativos de texto con el fin de facilitar su validación.

En la Figura 2 se puede apreciar cómo estos objetivos específicos atacan directamente a cada uno de los problemas causa identificados en la sección anterior.

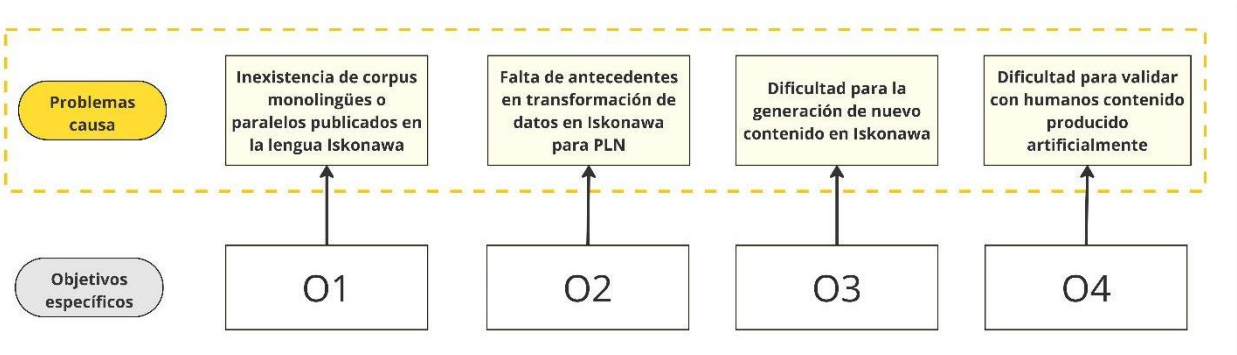

Figura 2. Relación de objetivos específicos con problemas causa

1.2.3. Resultados esperados.

A continuación, se listan los resultados esperados por cada objetivo específico:

O1. Diseñar y desarrollar un corpus monolingüe de la lengua Iskonawa.

R1.1 Definición de la estructura del corpus monolingüe.

R1.2 Corpus monolingüe desarrollado y listo para su uso en el modelo.

O2. Aplicar técnicas de preprocesamiento, aumentación y vectorización a los datos del corpus en Iskonawa para definir una estructura de trabajo replicable para futuros proyectos.

R2.1 Definición del pipeline de preprocesamiento, aumentación y vectorización al que los datos serán sometidos.

R2.2 Pipeline de preprocesamiento, aumentación y vectorización completamente desarrollado.

O3. Diseñar modelos de generación automática de texto para la lengua Iskonawa basados en aprendizaje profundo.

R3.1 Definición de las arquitecturas de los modelos generativos de texto.

R3.2 Modelos generativos de texto desarrollados y entrenados.

O4. Elaborar un prototipo de aplicación que use el contenido de los modelos generativos de texto con el fin de facilitar su validación.

R4.1 Definición de la arquitectura del prototipo de aplicación.

R4.2 Definición del protocolo de revisión manual de la calidad del contenido generado

R4.3 Prototipo de aplicación desplegado y listo para su uso.

1.2.4. Mapeo de objetivos, resultados y medios de verificación.

Se muestra en la Tabla 1, Tabla 2, Tabla 3 y Tabla 4 los medios de verificación que permitirán validar cada uno de los resultados esperados descritos anteriormente.

Tabla 1.

Medios de verificación e IOV del objetivo específico 1

Objetivo 1. Diseñar y desarrollar un corpus monolingüe de la lengua Iskonawa.			
Resultado		Medio de verificación	Indicador objetivamente verificable
R1.1	Definición de la estructura del corpus	Documento con la definición de la estructura del corpus	El reporte debe describir cómo estará estructurado el corpus y dicha estructura debe ser validado por una persona experta en el procesamiento de lenguaje natural.
R1.2	Corpus desarrollado y listo para usar	Archivo con el corpus extraído en un formato leíble por computador	Validación en estructura de corpus monolingüe final por parte de persona experta en PLN

Tabla 2.

Medios de verificación e IOV del objetivo específico 2

Objetivo 2. Aplicar técnicas de preprocesamiento, aumentación y vectorización al conjunto de datos en Iskonawa para definir una estructura de trabajo replicable para futuros proyectos.			
Resultado		**Medio de verificación**	**Indicador objetivamente verificable**
R2.1	Definición del pipeline de preprocesamiento, aumentación y vectorización al que los datos serán sometidos	Documento con el diseño del pipeline de preprocesamiento, vectorización y aumentación	El documento debe describir el flujo de métodos al que los datos serán sometidos. Dicho flujo debe estar validado por un experto en PLN.
R2.2	Pipeline de preprocesamiento, aumentación y vectorización completamente desarrollado	Pipeline implementado en su totalidad	Validación del funcionamiento del pipeline mediante su uso en una tarea de clusterización

Tabla 3.

Medios de verificación e IOV del objetivo específico 3

Objetivo 3. Diseñar modelos de generación automática de texto para la lengua Iskonawa basados en aprendizaje profundo.			
Resultado		Medio de verificación	Indicador objetivamente verificable
R3.1	Definición de las arquitecturas de los modelos generativo de texto	Documento de definición de la arquitectura del modelo generativo de texto	El documento debe describir arquitecturas validadas por un experto en PLN
R3.2	Modelos generativos de texto desarrollados y entrenados	Archivo con el modelo ya entrenado	Validación del contenido generado del modelo mediante 2 métricas automáticas
		Documento con resultados del modelo en métricas automáticas	

Tabla 4.

Medios de verificación e IOV del objetivo específico 4

Objetivo 4. Elaborar un prototipo de aplicación que use el contenido de los modelos generativos de texto con el fin de facilitar su validación.			
Resultado		**Medio de verificación**	**Indicador objetivamente verificable**
R4.1	Definición de la arquitectura del prototipo de aplicación	Documento con la definición de la arquitectura del prototipo de aplicación	El documento debe describir una arquitectura validada por un experto en despliegue de aplicaciones de PLN
R4.2	Definición del protocolo de revisión manual de la calidad del contenido generado	Documento con el protocolo de revisión del contenido generado para su validación manual	Validación del protocolo de revisión por un experto en validación de PLN
R4.3	Prototipo de aplicación desplegado y listo para su uso	Acceso al prototipo de aplicación desplegado	Flujo de uso de prototipo de aplicación realizado y validado por 5 usuarios
			Validación del contenido generado por un experto en la lengua a un nivel del 70% en fluidez, pertinencia y correctitud.

1.3. Métodos y Procedimientos

En esta sección se muestran[2] las herramientas, métodos y procedimientos que se utilizarán para el desarrollo del proyecto. Se menciona cuáles de estos serán utilizados en cada uno de los resultados esperados. Asimismo, se ofrece una concisa descripción de cada uno de estas herramientas, métodos o procedimientos y se describe cómo serán de utilidad para el desarrollo proyecto.

1.3.1 Herramientas, métodos y procedimientos por resultado esperado

En la Tabla 5 se lista el uso de herramientas, métodos y procedimientos por cada uno de los resultados esperados.

[2] Se ha omitido de esta sección el software de ofimática dado su uso continuo en todo el proyecto.

Tabla 5.

Herramientas, métodos y procedimientos a ser usados en cada resultado esperado

Objetivo específico	Resultado esperado	Herramientas	Métodos y procedimientos
O1	R1.1. Definición de la estructura del corpus monolingüe	No aplica	No aplica
	R.1.2. Corpus monolingüe desarrollado y listo para usar	Python, cuadernos Jupyter, Pandas	No aplica
O2	R2.1. Definición del pipeline de preprocesamiento, aumentación y vectorización al que los datos serán sometidos	No aplica	Representaciones vectoriales, aumentación de datos
	R2.2. Pipeline de preprocesamiento, aumentación y vectorización completamente desarrollado	Python, cuadernos Jupyter, NLTK	Representaciones vectoriales, aumentación de datos
O3	R3.1. Definición de las arquitecturas de los modelos generativo de texto	No aplica	Transformer, modelos pre-entrenados, transferencia de aprendizaje
	R3.2. Modelos generativos de texto desarrollados y entrenados	Python, cuadernos Jupyter, Pytorch	Evaluación del modelo generativo
O4	R4.1. Definición de la arquitectura del prototipo de aplicación	No aplica	No aplica
	R4.2. Definición del protocolo de revisión manual de la calidad del contenido generado	No aplica	Evaluación del modelo generativo
	R4.3. Prototipo de aplicación desplegado y listo para su uso	Python, Flask	Evaluación del modelo generativo