Capítulo 4. Desarrollo del corpus en Iskonawa

En este capítulo se detallarán las acciones realizadas para extraer el corpus de datos en el Iskonawa que se usará para llevar a cabo este proyecto. El objetivo específico que se busca alcanzar es el O1 (Diseñar y desarrollar un corpus monolingüe de la lengua Iskonawa.). Se empezará detallando el origen y naturaleza de los datos. Luego, se explicará la estructura definida para el corpus y, finalmente, las acciones realizadas para conseguir su extracción. Durante el desarrollo de este capítulo se usarán los términos atributo y columna intercambiablemente.

4.1. Origen y naturaleza de los datos

Los datos con los que se cuenta son el producto de un proyecto de investigación denominado "Documentación y Revitalización del Iskonawa (ISC): un proyecto interdisciplinario" llevado a cabo entre 2012 y 2015 (Zariquiey, 2015). Este proyecto, administrado por la TUFTS University y la Pontificia Universidad Católica del Perú, tuvo como uno de sus resultados veinte horas de horas de material audiovisual, de las cuales seis han sido transcritas y traducidas al español.

Dicho material es el que servirá de base para el desarrollo de este corpus. Pertenece al dominio de canciones, conversaciones e historias contadas por los Iskonawa a los investigadores. Por ejemplo, algunos de los títulos son "Narración chacra", "Canción bebida" o "Cuento animal". Este material fue facilitado por el profesor Roberto Zariquiey, pero también se encuentra libre para su descarga en el Archivo Digital de Lenguas Peruanas[3].

Se cuenta principalmente con dos tipos de archivo. Los primeros están en formato *txt* y cuentan con la siguiente información: número de identificación del registro *(\ref)*, transcripción del Iskonawa *(\trs)*, alineado por palabras (*\tx*), segmentación morfológica *(\mb)*, glosa en español *(\gn)*, etiqueta de parte del habla *(\ps)*, traducción libre *(\ft)* y nombre del hablante *(\ELANParticipant)*. En la Figura 4 se puede ver un ejemplo de un registro. Las anotaciones iniciales indican el tipo de información que la fila contiene. Como se aprecia, hay otros datos que no han sido considerados, pues hacen referencia al material audiovisual y no son relevantes

[3] Cuentos: https://datos.pucp.edu.pe/dataset.xhtml?persistentId=hdl:20.500.12534/1EAZHO# canciones: https://datos.pucp.edu.pe/dataset.xhtml?persistentId=hdl:20.500.12534/4RIRF8 y narraciones y conversaciones: https://datos.pucp.edu.pe/dataset.xhtml?persistentId=hdl:20.500.12534/4CTKGE

para este proyecto (***ELANBegin** y ***ELANEnd***, por ejemplo, marcan el intervalo de tiempo del video en el que el participante habla).

```
\ref 012
\ELANBegin 34.930
\ELANEnd 37.840
\ELANParticipant Isabel
\trs atapa kai akai kochi iná aki
\tx atapa       kai          akai              kochi
\mb atapa       ka     -i    ak      -ai       kochi
\gn gallina(SK) ir     -IMPF hacer   -IMPF(SK) cerdo
\ps n.          v.intr -suf. v.tran. -suf.     n.

\tx iná   aki
\mb iná   ak      -i
\gn criado hacer   -IMPF
\ps adj.   v.tran. -suf.

\ft voy a hacer aumentar gallinas y voy a criar chanchos
\sound IC-narracion.chacra-2013.wav 34.930 37.840
```

Figura 4. Ejemplo de registro en los archivos *txt*.

El otro tipo de archivos con los que se cuenta son de tipo *eaf*, un formato XML utilizado por el programa de anotación lingüística ELAN. Estos archivos solo cuentan con datos de la transcripción en Iskonawa y la traducción libre, mas no detalles lingüísticos como la segmentación morfológica o el glosado. En la Figura 5 se aprecia la forma en la que estos datos están guardados. Cada TIER (lo que se podría entender como una "columna") contiene anotaciones de las transcripciones (*trs*), alineamiento por palabras (*tx*) y traducción libre (*ft*).

```
<TIER LINGUISTIC_TYPE_REF="default-lt" PARTICIPANT="Germán" TIER_ID="trs@Germán">···
</TIER>
<TIER LINGUISTIC_TYPE_REF="association-it" PARENT_REF="trs@Germán" PARTICIPANT="Germán" TIER_ID="tx@Germán">
</TIER>
<TIER LINGUISTIC_TYPE_REF="association-it" PARENT_REF="trs@Germán" PARTICIPANT="Germán" TIER_ID="ft@Germán">
    <ANNOTATION>
        <REF_ANNOTATION ANNOTATION_ID="a292" ANNOTATION_REF="a98">
            <ANNOTATION_VALUE>(había un) hombre sonso</ANNOTATION_VALUE>
        </REF_ANNOTATION>
    </ANNOTATION>
    <ANNOTATION>···
    </ANNOTATION>
```

Figura 5. Ejemplo de un registro en los archivos *eaf*.

En total, se cuenta con 42 archivos *txt* y 9 archivos *eaf*. Se cuenta también con un archivo *txt* referente a un diccionario bilingüe Iskonawa-español. Este está estructurado de manera análoga a lo mostrado en la Figura 4. Sin embargo, sus registros no serán parte del corpus, pues solo son palabras sin contexto y sin formar parte de alguna oración. Se procesará y se almacenará

de forma separada para su posterior uso. En base a los datos presentes en estos archivos es que se definirá la estructura del corpus en la siguiente sección.

4.2. Resultados alcanzados

4.2.1. Estructura del corpus

Considerando los archivos descritos anteriormente, los atributos del corpus se eligieron con el fin de organizar todos los datos con los que se contaba. Se describe en la Tabla 12 el detalle de cada uno de dichos atributos. Asimismo, se indica si el atributo en cuestión puede no estar presente en algún registro. Este es el caso de las columnas *text*, *morpheme_break*, *pos* y *gloss_es*, pues los archivos *eaf* no cuentan con estos datos.

Tabla 12

Descripción de los atributos del corpus en Iskonawa

Atributo	**Descripción**	**¿Contiene nulos?**
id	Identificador único para cada registro en el corpus.	No
speaker	Identificador del hablante del texto.	No
transcription	Transcripción textual del audio original en Iskonawa.	No
text	Texto palabra por palabra alineado con las anotaciones lingüísticas en Iskonawa.	Sí
morpheme_break	Segmentación morfológica del texto en Iskonawa.	Sí
pos	Etiquetas de partes del habla (POS) de cada morfema en Iskonawa. Alineado con morpheme_break si este no es nulo.	Sí
gloss_es	Glosa en español que proporciona una explicación morfema por morfema. Alineado con morpheme_break si este no es nulo.	Sí
free_translation	Traducción libre del Iskonawa al español.	No
file	Nombre del archivo de origen del texto.	No

Todos los datos están en forma de cadenas. Los datos se guardarán en un archivo JSON el cual estará almacenado en un repositorio en GitHub para facilitar su posterior descargar en otras instancias. En la Tabla 13 se muestra un ejemplo de cómo se vería una entrada en el corpus de acuerdo a las columnas descritas en la tabla anterior.

Tabla 13

Ejemplo de entrada en el corpus

Columna	**Valor**
id	JC.NC.IC-conversacion.varios-2013_018
speaker	Juanita
transcription	waka pokebaini kai
text	waka pokebaini kai
morpheme_break	waka poke -bain -i ka -i
pos	n. v. -suf. -suf. v.intr -suf.
gloss_es	río cruzar -yendo:TRAN -SUJ>S:SIM ir -IMPF
free_translation	El río lo cruzaron.
file	JC.NC.IC-conversacion.varios-2013.txt

Como se describió en el Capítulo 1, esta estructura fue validada con un experto en procesamiento de lenguaje natural para asegurar su utilidad para las siguientes tareas. El documento con dicha validación puede ser encontrado en el Anexo C.

4.2.2. Extracción del corpus

Una vez definida la estructura, se desarrollaron las funciones necesarias para extraer los datos de los dos tipos de archivos descritos y estructurarlos en el formato definido. Estas tareas fueron llevadas a cabo utilizando Python y la librería Pandas.

El primer paso fue leer los archivos, extraer los datos necesarios por cada registro y almacenarlos en una estructura de tipo diccionario. Luego, este diccionario se convirtió a una estructura DataFrame de Pandas para facilitar las operaciones con los datos. Aquí se realizó una limpieza de registros donde se eliminaron aquellas entradas que cumpliesen con alguna de las siguientes características:

- El contenido en la columna *transcription* es principalmente en español. Para esto se utilizó el módulo langdetect. Se eliminaron estos registros debido a que correspondían a contenido en español hablado por los investigadores o por los Iskonawa.
- El contenido en la columna *transcription* es vacío. Se eliminaron estas filas porque carecían de contenido útil para el modelo.
- El registro se encuentra duplicado en los atributos de *transcription* y *gloss_es*. Estos registros aparecen en ocasiones como resultado de una repetición de los hablantes en el contexto de canciones.

Después de haber realizado esta eliminación, se cambiaron aquellas cadenas vacías o solo con espacios en blanco por un valor nulo con el fin de normalizar estos valores. Se quitaron también caracteres no alfabéticos ni signos de puntuación que se encontraron en algunos textos (como "\"). Finalmente, se normalizaron las etiquetas de parte del habla, pues se encontraron varias formas para una misma etiqueta (por ejemplo, "adv", "adv." y "advv." para adverbio). Se comprobó la inexistencia de nulos en las columnas que lo requerían, se guardó la estructura en formato JSON y se subió finalmente al repositorio remoto para su descarga. La cifra final de registros fue de 3942.

Para verificar que el resultado fue alcanzado, se creó un breve cuaderno de validación[4] donde se leyó el archivo JSON desde el repositorio. Se comprobó que la cantidad de registros leída fue igual a la guardada originalmente y se corroboró que no existieran valores nulos en las columnas detalladas como sin valores nulos en la estructura. Finalmente, un validador ejecutó este cuaderno para dar su visto bueno, el cual puede ser consultado en el Anexo C1. Luego de la revisión, se verificó que la estructura era favorable y se corrigieron algunos fallos de duplicación encontrados por el validador.

4.3. Discusión

En este capítulo se presentaron los resultados alcanzados referentes al diseño y extracción del corpus en Iskonawa. Se detalló la estructura que seguiría el conjunto de datos y se mostró la serie de pasos seguidos para extraer y almacenar los datos. Estos resultados fueron validados por un experto en procesamiento de lenguaje natural.

[4] Puede ser consultado aquí: https://github.com/Xnehil/Tesis/blob/main/O1_Corpus/ValidacionCorpus.ipynb

Completar este objetivo representa la creación de un corpus leíble por computador en una lengua que antes no tenía este tipo de recursos. Investigaciones en otras lenguas peruanas han reportado un mayor número de registros, como corpus de 22460 oraciones en Shipibo-Konibo y un corpus de 18000 oraciones en Yanesha (Bustamante et al., 2020) o incluso la significante cifra de 384184 oraciones en Quechua Chanka y Collao presentadas en (Zevallos et al., 2022). Si bien la cifra obtenida en el corpus presentado es menor, esto corresponde a la naturaleza de extremo peligro del Iskonawa. Las oraciones recolectadas por Bustamente y Zevallos fueron extraídas de una variedad de documentos *pdf* de textos educativos. Sin embargo, no existen material similar en Iskonawa y la población hablante es mucho menor.

Pese a que el número pueda parecer bajo, la creación de este corpus supone un avance en la investigación en Iskonawa, pues ya se tiene un conjunto de datos listo para descargar y usar en distintas aplicaciones de PLN. Además, los resultados alcanzados representan una forma de estructurar futuros corpus, sean en esta u otras lenguas, que tengan como materia prima a datos de anotaciones lingüísticas realizados con el programa ELAN.