Capítulo 7. Prototipo de aplicación para la validación del contenido generado

En este capítulo se describirá la aplicación elegida para dar soporte a la validación del contenido generado. Se empezará describiendo la arquitectura elegida para la aplicación. A continuación, se definirá el protocolo de revisión del contenido generado que la aplicación debe facilitar. A continuación, se mostrará en los resultados alcanzados el diseño de las interfaces y se explicará qué se buscó priorizar con ellas y cómo ayudan a llevar a cabo el protocolo de revisión definido. Finalmente, se mostrarán los resultados obtenidos luego de ejecutar el protocolo de revisión con un experto en la lengua.

7.1 Aplicación de validación

Como se describió en el O4, el objetivo de esta aplicación es facilitar la validación con humanos del contenido generado. Con el fin de no restringir su uso a este estudio y solo al Iskonawa, se definió una arquitectura que permita usar la aplicación con otras lenguas y otras métricas. A continuación, se describe la arquitectura diseñada con este objetivo en mente.

7.1.1 Arquitectura de aplicación

Desde el punto de vista físico, se busca crear una aplicación ligera y que pueda ser fácilmente desplegada. Como se describió en la sección 1.3, el framework a utilizar fue Flask debido a su enfoque minimalista. Se decidió no utilizar algún framework frontend debido a que no existía necesidad de complejidad en esta capa. En la Figura 12 se muestra esto, donde el servidor web Flask aloja tanto las páginas web estáticas como los servicios del backend. Para esta versión del prototipo, la base de datos a utilizar será SQLite debido a la baja escala de la cantidad de ejemplos y evaluadores. Tanto la aplicación como la base de datos estarían alojada en un único servidor Ubuntu.

En principio, no se tiene planeado realizar más inferencias para realizar las pruebas. Se cargarán los ejemplos generados en el capítulo anterior para que sean evaluados. Sin embargo, se dejó disponible el campo para que en algún trabajo futuro se implemente esta funcionalidad.

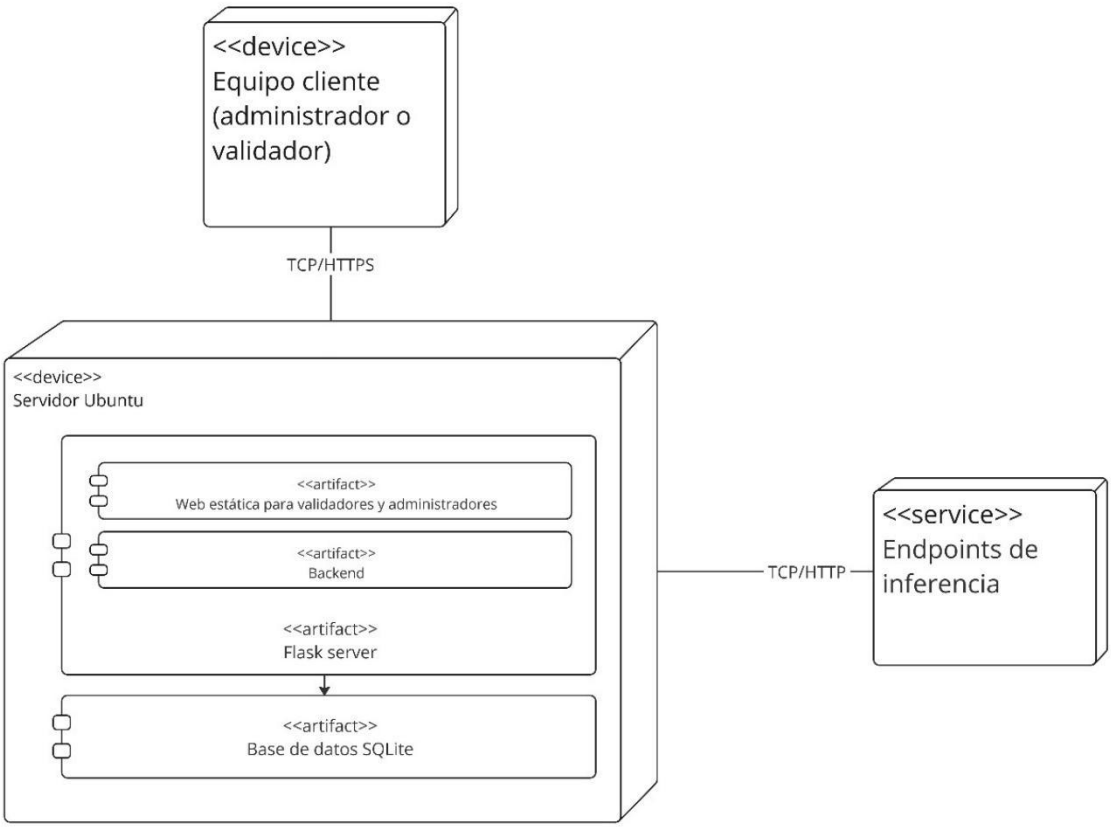

Figura 12. Vista física de la aplicación de validación

Desde el punto de vista lógico, en la Figura 13 se muestra el diagrama de clases definido para la aplicación. A continuación, se proporciona una descripción de las clases identificadas:

- **Lengua:** Contiene el nombre e isocode (ISO 639-3) de una lengua a ser evaluada.
- **Ejemplo:** Texto a ser evaluado. Es de una lengua en específico y fue generado por un modelo en específico.
- **Modelo:** Modelo que generó ciertos ejemplos. Existirá uno con nombre "real" para ejemplos que hayan sido producidos por hablantes. En el atributo endpoint se indicará a dónde realizar una solicitud en caso se desee generar más ejemplos.
- **Experimento:** Representa un experimento en el que se seleccionarán cierto número de ejemplos de determinada lengua para ser evaluados.
- **Experimento_X_Ejemplo:** Entidad cruce. Representa a un ejemplo asignado a cierto experimento.
- **Validación:** La validación realizada por un validador a un ejemplo dentro de cierto experimento.
- **Validador:** Persona conocedora de la lengua (ya sea nativa o experta). El propósito de esta entidad es asegurar que en el experimento exista el especificado número de validadores y se pueda guardar el progreso de cada uno.

- **Métrica:** Se consideró esta entidad para soportar la posibilidad de agregar métricas personalizadas. Al crear un experimento, se decide qué métricas serán evaluadas.
- **PuntuaciónMétrica:** Corresponde al valor asignado por un validador a una métrica en cuestión durante una validación.

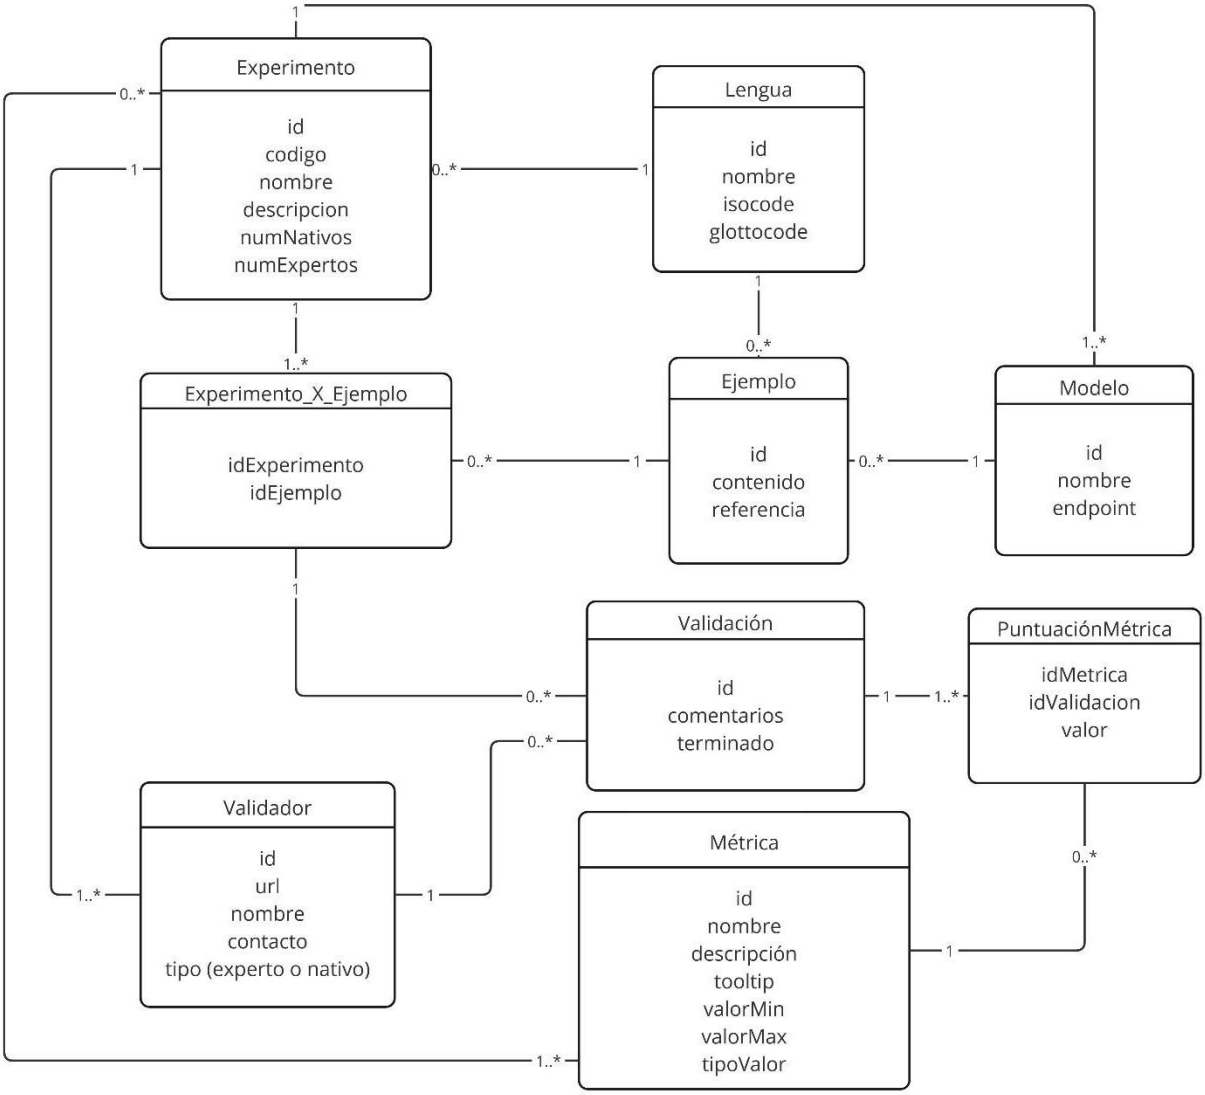

Figura 13. Vista lógica final de la aplicación de validación. Se compartió una versión anterior con el experto y sus comentarios fueron considerados

7.1.2 Protocolo de validación

En esta sección se ofrece una descripción de qué se validará para este estudio y cómo se llevará a cabo mediante el uso de la aplicación. Para empezar, se consultaron estudios similares (Maurya et al., 2021), (Kale y Roy, 2020) y (Chi et al., 2019) para escoger qué métricas debían ser evaluadas. Se identificó que en las validaciones manuales realizadas se suele medir al contenido generado en tres aspectos:

- **Fluidez:** Qué tan fluido y natural es el texto generado en Iskonawa. Se asignará un puntaje del 1 al 5, donde 1 es el valor más bajo.
- **Correctitud:** Qué tan correcto es gramatical y sintácticamente el contenido. No se espera un análisis detallado. Los valores, al igual que con fluidez, irán de 1 al 5, donde 1 es el valor más bajo.
- **Pertinencia:** Valor booleano que indica si el contenido aparenta ser Iskonawa o no.

Una vez definidas estas métricas, se describe en la Figura 14 el flujo que se realizaría para ejecutar este experimento. Este comienza de parte del gestor del experimento, quien previamente ya ha subido archivos con los ejemplos a evaluar. En la plataforma, el gestor elige la lengua a evaluar, elige los modelos que entrarán en la evaluación (incluyendo al modelo "real", correspondiente a ejemplos producidos por humanos), el número de ejemplos y elige las métricas a evaluar (en nuestro caso, fluidez, correctitud y pertinencia). Luego, elige cuántos evaluadores participarán del experimento. Al terminar la creación del experimento, se le proporciona al gestor un código para que pueda volver al experimento, así como los enlaces de invitación para que los distribuya a los evaluadores que considere.

Por parte de cualquiera de los evaluadores, estos ingresarán a la aplicación a través del enlace proporcionado por el gestor. Al ingresar, verán un ejemplo al que deben evaluar en las métricas mostradas en pantalla. Repetirán esto por todos los ejemplos en el experimento. Podrán salir y volver a entrar en cualquier momento con el mismo enlace proporcionado. Al finalizar todos los ejemplos, se les agradecerá por su participación y el flujo volverá al gestor del experimento, quien esperará a que todos sus validadores completen los ejemplos para descargar los resultados.

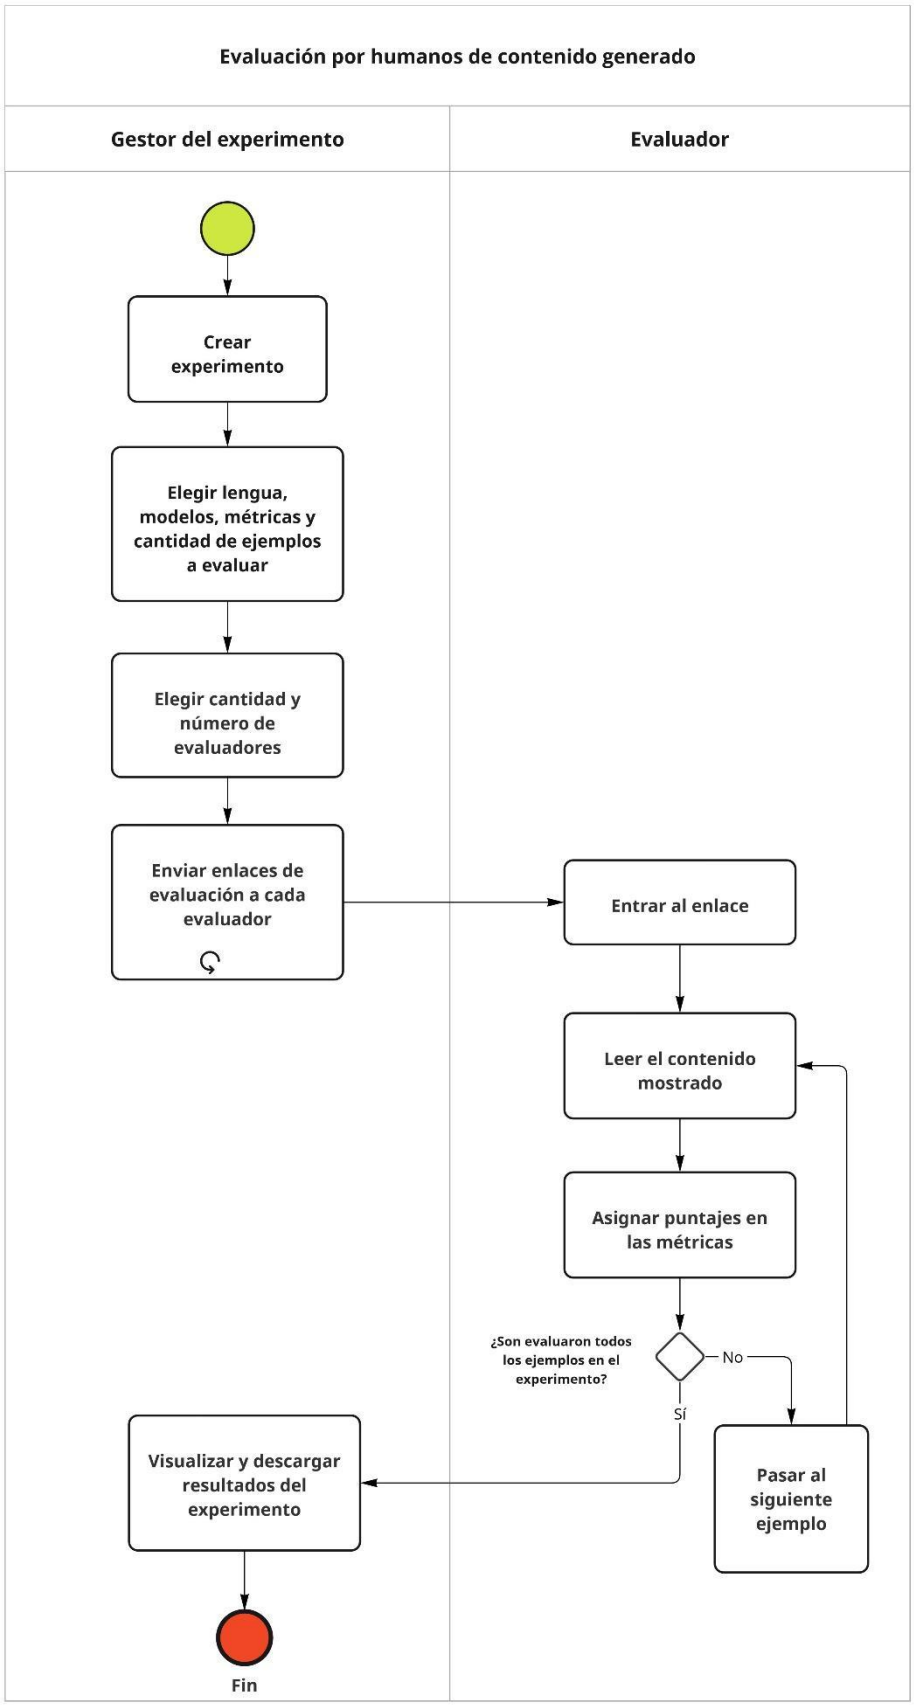

Figura 14. Flujo de validación del contenido generado en el prototipo de aplicación

7.1.3 Desarrollo y despliegue

En base a lo definido en la sección anterior, se consultó con un experto para recolectar su opinión respecto al protocolo de validación y la arquitectura. Luego de una revisión, se consideró el añadido de más atributos para hacer más versátil a la aplicación. El experto estuvo de acuerdo con la arquitectura y sugirió la posibilidad de añadir algunas medidas de seguridad, pero se decidió no implementarlas debido a que escapaban al enfoque de prueba de concepto de este prototipo. Estos resultados corresponden a los resultados esperados R4.1 y R4.2, para más detalle de los comentarios se sugiere consultar el Anexo C.

Una vez se refinaron esos aspectos, se comenzó la etapa de desarrollo del prototipo[12]. Cabe destacar que se priorizaron aspectos que permitían demostrar el funcionamiento del prototipo, tales como la creación de experimentos, el manejo de validadores, la compartición de enlaces y la descarga de los resultados del experimento.

En primer lugar, se da la bienvenida al usuario en la pantalla de inicio. Como se ve en la Figura 15, esta pantalla está pensada para usuarios en el rol de Gestor de experimento. Es decir, usuarios que planeen utilizar la plataforma para validar su contenido con otros expertos y nativos. No se prioriza aquí al rol de Validadores debido a que estos entrarán en el flujo a través de un enlace facilitado por el Gestor que los llevará directamente al proceso de validación.

[12] Código fuente del prototipo en este enlace:
https://github.com/Xnehil/Tesis/tree/main/O4_Aplicacion/validaciones

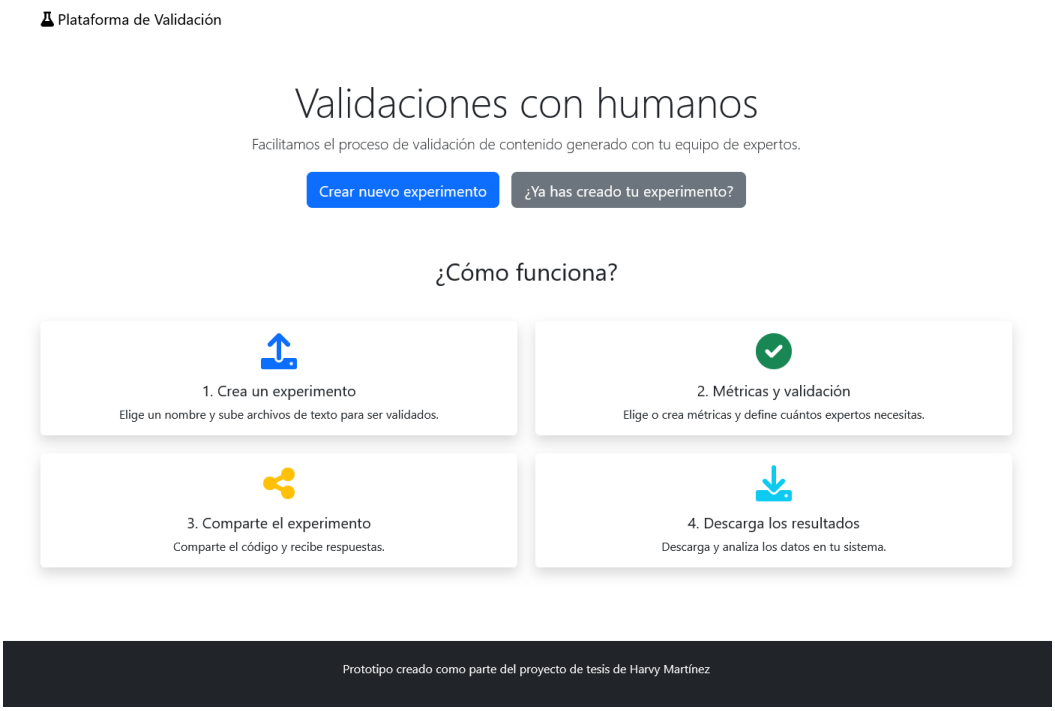

Figura 15. Pantalla de inicio del prototipo de aplicación

El flujo de creación de experimento consiste en 3 pasos: datos generales, contenido a evaluar y validación. En el primero, se le solicita al Gestor un nombre y una descripción para mostrar a sus evaluadores. Además, se le pide que seleccione la lengua que se está evaluando. El campo de lengua está poblado por una serie de lenguas del Perú obtenidas de la base de datos lingüística Glottolog (Hammarström et al., 2024). Luego, se le solicitan archivos en texto plano (.txt) que contienen las líneas o ejemplos a evaluar. Se considera un archivo por cada modelo o fuente y se decide qué tanto porcentaje de líneas se mostrará a los evaluadores. Finalmente, en la sección evaluación se solicita que se indique qué métricas se considerarán y cuántos evaluadores participarán del experimento. Por defecto se consideran las tres métricas mencionadas en la sección anterior (fluidez, correctitud y pertinencia), pero se deja abierta la opción para que puedan crearse métricas personalizadas. Para más detalle se pueden consultar las pantallas descritas en la Figura 23, Figura 24 y Figura 25 en el Anexo D.

Luego de crear el experimento, el Gestor es enviado a una pantalla de administración, donde puede ver los datos generales y de progreso de las validaciones en el experimento. Aquí también se le ofrecen los enlaces de invitación para compartir con sus validadores. En la Figura 16 se aprecia esto, donde se ve a la derecha la posibilidad de editar los datos del Validador y copiar el enlace de invitación.

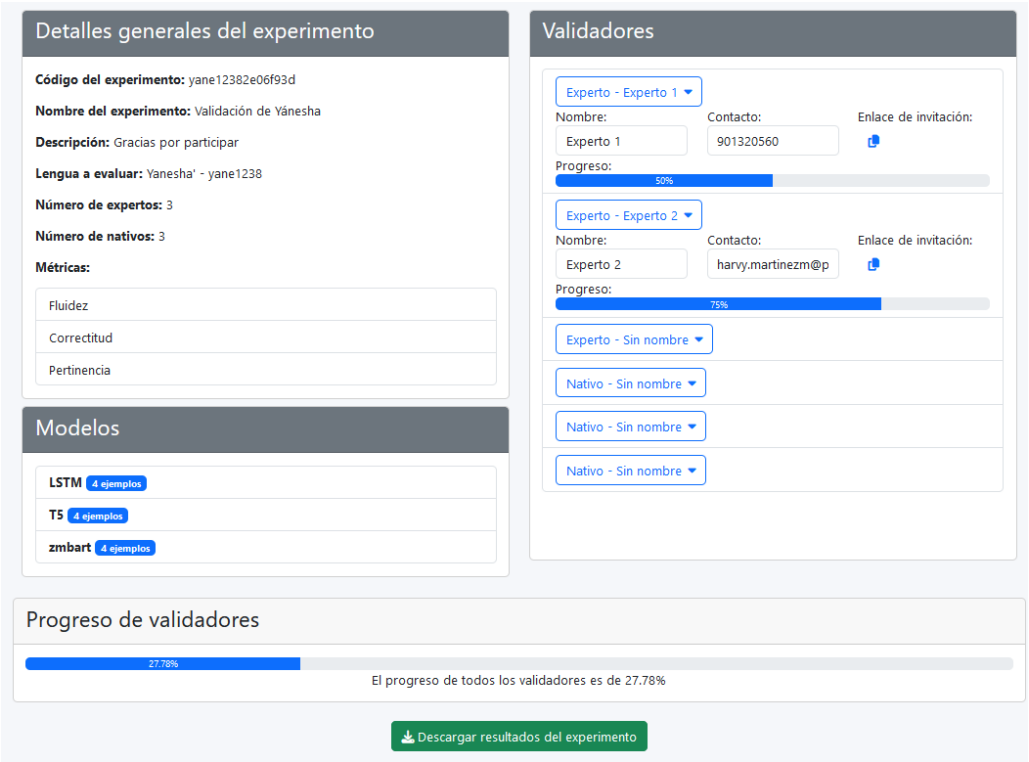

Figura 16. Pantalla de gestión del experimento. En este ejemplo, dos validadores ya han completado parte de sus ejemplos

Desde el punto de vista de los validadores, su rol en la aplicación iniciar cuando el Gestor les comparte el enlace de invitación. Al acceder con dicho enlace, se les muestra una pantalla de bienvenida con un ejemplo de la validación a realizar y la descripción facilitada por el Gestor. Una vez comienzan a validar, ven una pantalla como la mostrada en la Figura 17. Aquí se muestra el contenido a evaluar, así como las métricas que se hayan definido para las validaciones en este experimento. El progreso se guarda luego de terminar la evaluación de cada ejemplo, por lo que el Validador puede salir y continuar en otro momento con sus evaluaciones mediante el mismo enlace.

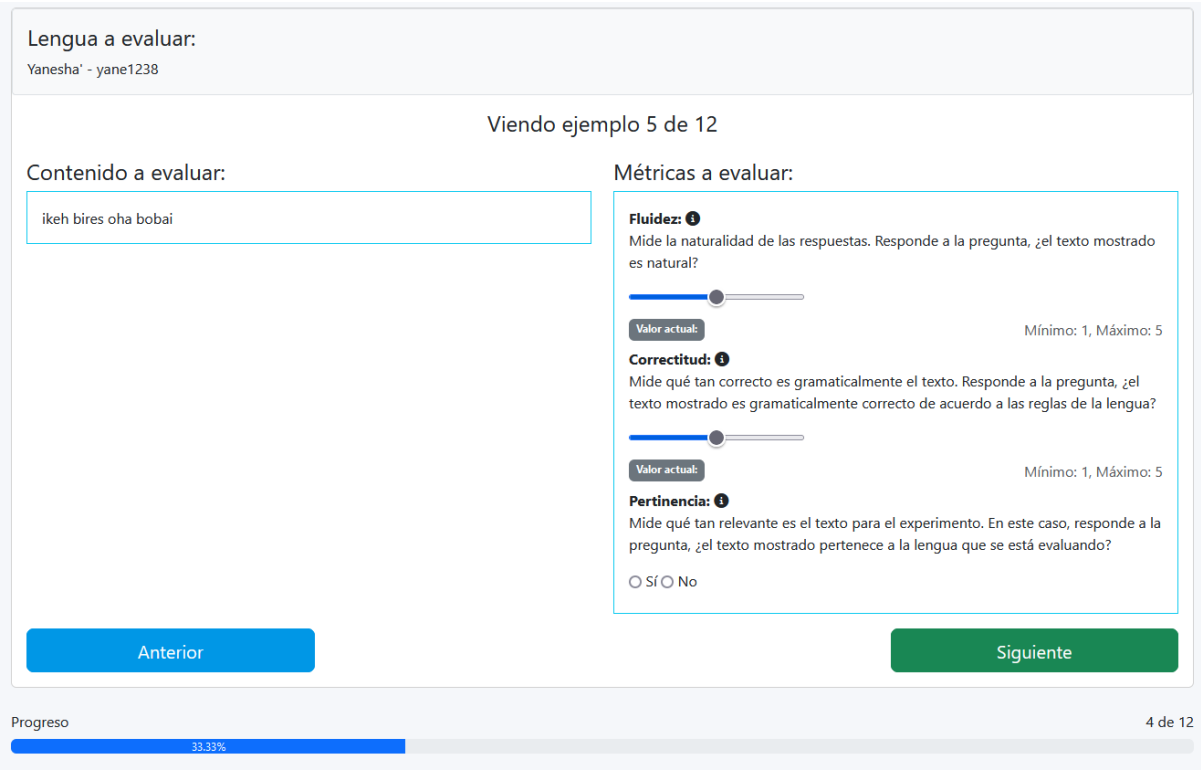

Figura 17. Pantalla de validación. En el ejemplo mostrado, el validador ya ha validado cuatro ejemplos y se encuentra en el quinto.

Cuando el Validador termine todas las validaciones, se agradece su participación y se le brinda la opción de volver a modificar de ser necesario. El Gestor puede descargar en cualquier momento los resultados que se tengan hasta el momento mediante el botón mostrado en la Figura 16. Esta opción le facilita un archivo separado por comas, donde cada registro corresponde a una puntuación dada a una métrica durante la validación de un ejemplo específico por un determinado validador. En la Tabla *16* se brindan detalles de los campos considerados para la descarga. Una vez se le facilita el archivo, el Gestor es libre de analizar los datos de su experimento con la herramienta que considere más apropiada.

Tabla 19

Campos considerados en la descarga del archivo de resultados del experimento

Nombre del campo	**Descripción**	**Ejemplo**
validador_id	Identificador numérico del Validador	1258
validador_nombre	Nombre del Validador detallado por el Gestor	Carlos

Nombre del campo	Descripción	Ejemplo
modelo_nombre	Nombre del modelo del que se originó el ejemplo evaluado	LSTM_v4
ejemplo_id	Identificador numérico del ejemplo	141555
ejemplo_contenido	Contenido del ejemplo	tiki sawepaoniir hainra paeahonhe pachonheró
metrica_nombre	Nombre de la métrica a la que corresponde esta puntuación	Fluidez
puntuacion_valor	Valor de la puntuación asignada por el Validador	4

7.2 Resultados alcanzados

Una vez se contó con el prototipo de aplicación listo para ser usado, se procedió a diseñar las pruebas de validación que se ejecutarían. Por un lado, el flujo de validación en el prototipo de aplicación sería validado por cinco usuarios distintos. Por otro lado, se ejecutaría mencionado flujo con el experto en Iskonawa para obtener una evaluación más precisa sobre el contenido generado.

7.3.1 Prototipo de aplicación

Como se definió en el Resultado Esperado 4.3, uno de los indicadores fue la validación del flujo de uso de la aplicación. Para ello, se consideró que el flujo a validar consistiría en el correspondiente al rol de Validador, pues era el que sería posteriormente usado por un validador real. La prueba consistió en crear un experimento con 12 ejemplos que validar. Este experimento se creó considerando 5 validadores. El enlace de invitación fue compartido con cinco 5 usuarios distintos, a los cuales se les dieron las siguientes indicaciones:

- Suponga que es un experto en la lengua Iskonawa
- Entre al enlace que se le proporciona a continuación
- Sigas las indicaciones que se muestran y complete todas las validaciones

Se estuvo presente durante cada una de validaciones para observar la interacción de los usuarios, pero no se les ayudó en la realización del flujo. Esta prueba fue grabada previo acuerdo oral con el participante. Posterior a la realización del ejercicio, se le facilitó a los usuarios un enlace con un cuestionario basado en las preguntas de la Escala de Usabilidad del Sistema (SUS, por sus siglas en inglés) (Brooke, 1995). Este es un cuestionario muy usado en el área de interacción humano-computador. Si bien puede ser considerado antiguo, aún es relevante y ha demostrado devolver resultados confiables (Tullis y Stetson, 2004). El objetivo de esta prueba, más allá de obtener un puntaje respecto a la usabilidad del sistema, fue el de detectar posibles errores, ambigüedades y puntos de confusión. De esta forma, estos podrían solucionarse antes de exponer la aplicación al experto en Iskonawa.

Cuando se terminaron las evaluaciones, se procesaron las respuesta del cuestionario y se obtuvo un puntaje de **81,5** de acuerdo al método de puntuación descrito en (Brooke, 1995). Este puntaje corresponde a un puntaje superior al del percentil 85%, lo que puede ser descrito como un rendimiento aceptable y con el adjetivo de *bueno* (Sauro, 2018). Por otro lado, mediante el análisis de las grabaciones de las pruebas y las preguntas realizadas, se identificó que los puntos de confusión más comunes entre los validadores eran:

- Falta de confirmación al avanzar entre validaciones. No se sentía feedback al avanzar entre ejemplos
- Exceso de texto en la descripción de las métricas. Se mencionó que actuó como distractor y podría resultar perjudicial al usar la aplicación con personas sin tanto dominio tecnológico
- Errores menores visuales (un contador que no se actualizó en un momento y un texto de bienvenida que no podía leerse bien

En general, todos los usuarios lograron completar el flujo de validación en la aplicación y manifestaron que una vez estuvieron puntuando los ejemplos, la aplicación se sintió fluida e intuitiva. Luego de atender los puntos de mejora descritos anteriormente, se pasó a la etapa final donde se usaría la aplicación con el experto en Iskonawa.

7.3.2 Resultados de validación con experto

Al igual que en la prueba anterior, el primer paso fue crear el experimento. Los modelos a evaluar en esta validación fueron 3 de los probados en el Capítulo 6: LSTM, MetaXNLG y ZmBART. El modelo T5 no se incluyó con el fin de no saturar al experto con ejemplos y debido

a que los ejemplos que produjo eran visiblemente inútiles (repeticiones excesivas). Además, se agregaron ejemplos obtenidos de mediante las técnicas de aumentación descritas en el Capítulo 5. Es decir, se contó con 4 fuentes distintas de donde provendría el contenido a ser evaluado. Por cada una de estas fuentes, se consideraron 8 ejemplos a evaluar. Finalmente, se agregaron 8 oraciones provenientes del corpus original para actuar como grupo de control del experimento. En total, el experto puntuaría un total de 40 ejemplos. Si bien en otros trabajos el número de ejemplos dados a validadores humanos va entre los 50 y 100 por modelo (Maurya et al., 2021), se tomó la decisión de validar solo 40 ejemplos en total con el fin de reducir el riesgo de abandono del experto y asegurar la calidad de sus validaciones, pues era el único humano con conocimientos de la lengua con el que se contaba.

Luego de que el experto terminó de realizar sus validaciones, se descargaron los resultados y se consolidaron en la Tabla 20. Se muestra en dicha tabla el promedio de los valores asignados a la fluidez y correctitud, los cuales pueden ir de 1 (nada fluido o nada correcto) a 5 (del todo fluido o del todo correcto). Además, la pertinencia total indica el porcentaje de ejemplos que fueron catalogados como aparentemente Iskonawa.

Tabla 20

Resultados de la evaluación con el experto sobre el contenido generado.

Fuente	**Fluidez promedio**	**Correctitud promedio**	**Pertinencia total**
ZmBART	1,75	1,88	37,5%
MetaXNLG	2,75	3,25	87,5%
LSTM	1,63	1,63	37,5%
Datos aumentados	4,38	4,25	100%
Datos originales	4,63	4,63	100%

7.3 Discusión

En este capítulo se abordó el diseño de la arquitectura del prototipo de aplicación de validación, así como el diseño del protocolo de validación que se seguiría en este sistema. Se definieron las vistas lógicas y físicas que darían soporte a este prototipo, así como el flujo de uso que un Gesto o un Validador seguirían. El flujo de validación fue ejecutado por 5 usuarios, quienes lograron terminar todas sus validaciones y calificaron a la aplicación como intuitiva y fluida. Además, se consideró la usabilidad de la aplicación como en un nivel aceptable de acuerdo al cuestionario SUS. Finalmente, la aplicación fue pulida y expuesta al experto en Iskonawa, donde se evaluaron los modelos anteriormente entrenados y un conjunto adicional de ejemplos aumentados originales.

El desarrollo de este prototipo representa un primer paso en una posible aplicación más completa para facilitar la evaluación de contenido generado por modelos de lenguaje. Si bien ya existen alternativas en el mercado como Prolific, Amazon Mechanical Turk, HumanSignal y otras, estas están enfocadas a un sector más empresarial, lo que no las hace tan atractivas para investigadores o grupos sin tantos recursos. Por otro lado, existen alternativas de código abierto que pueden usarse libremente, como LabelStudio. Sin embargo, estas están disponibles por defecto solo en inglés, la creación de un proyecto puede requerir conocimientos técnicos y no están totalmente pensadas para evaluadores sin familiaridad con la tecnología. En ese sentido, la prueba de concepto mostrada aquí puede expandirse en un proyecto futuro para atender esa necesidad de una aplicación que permita una sencilla creación de experimentos de validación y sea fácilmente usable por personas sin dominio tecnológico.

Finalmente, los resultados respecto a la validación con el experto confirmaron la hipótesis planteada en el capítulo anterior respecto a que los modelos entrenados no fueron eficaces al generar nuevo contenido en Iskonawa. Las puntuaciones que se obtuvieron en los 3 modelos reflejan una muy baja fluidez y correctitud. Si bien MetaXNLG logra los mejores resultados entre ellos y aparenta producir Iskonawa en la mayoría de los ejemplos, su fluidez y correctitud promedios se quedan en un valor indeseable. Esto nos indica que este acercamiento a la generación de lenguaje no es la más efectiva en este caso concreto, pues no se obtuvo contenido útil de acuerdo a las métricas elegidas. Sin embargo, los resultados obtenidos en el conjunto de ejemplos de datos aumentados dan un indicio de que optar por métodos basados en reglas y conocimiento lingüístico puede ser más efectivo al generar contenido con tan pocos recursos. Las puntuaciones alcanzadas por este conjunto se acercan bastante a los del contenido real. En

ese sentido, se recomienda que en un trabajo futuro se profundice en las técnicas de aumentación utilizadas y pueda crearse una herramienta en la forma de un paquete de Python fácilmente distribuible que pueda ser usado por otros investigadores en lenguas de bajos recursos.